Samuel David Buendia
Parcial Redes Neuronales

## Ejercicio 1 — Clasificación lineal básica

Separar **dos clusters de puntos** utilizando una red neuronal simple y analizar cómo influyen las funciones de activación y el learning rate.
Dataset: **Two Clusters**

**Datos iniciales**
Hidden layers: 1
Neuronas: 1
Activation: Tanh
Learning rate: 0.03

**Resultados**

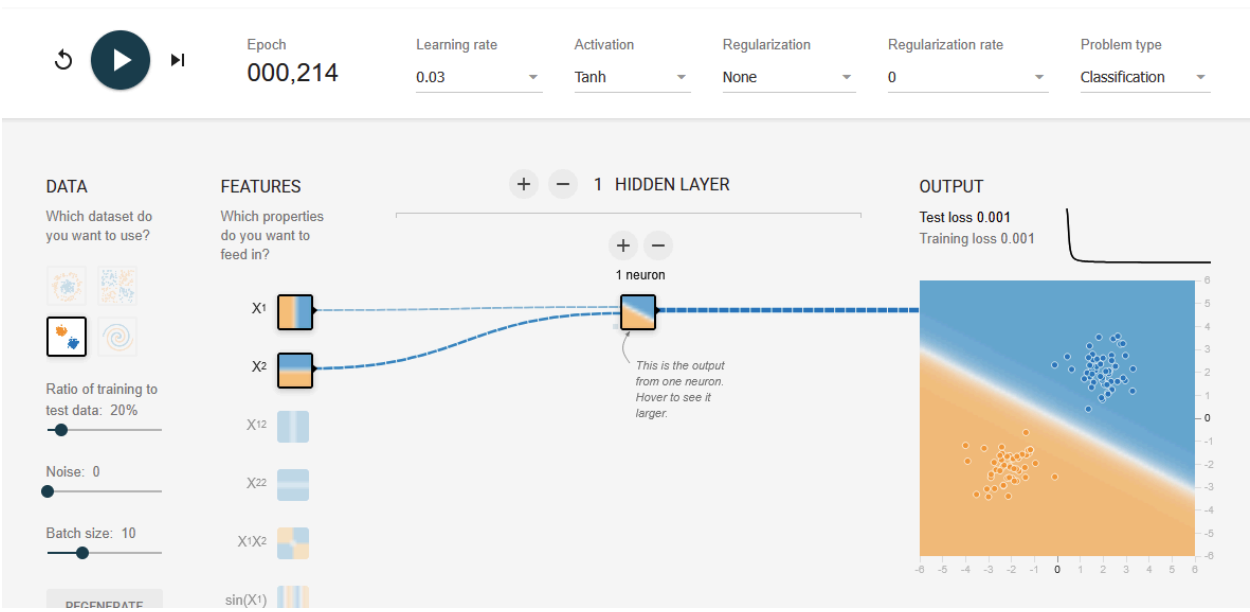


**Parametros recomendados**
Hidden layers: 1
Neuronas: 1
Activation: ReLU

Learning rate: 0.03

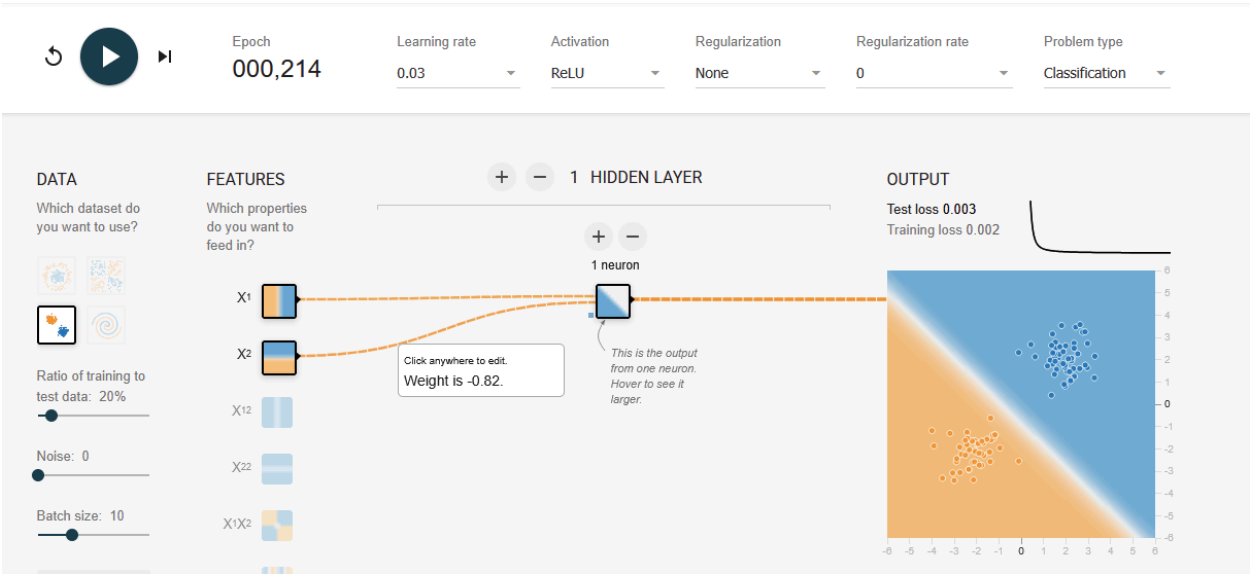


Justificacion
Los hiperparametros recomendados fueron elegidos debido a que al ser una separación simple no necesitan una red compleja, utilizar ReLu como función de activación permite un entrenamiento más estable y constante.

¿Con qué función de activación aprende más rápido?
Con ReLU, porque normalmente se encuentran mas rapido que Tahn o sigmod

¿Qué pasa cuando el learning rate es muy alto?
La red aprende de forma inestable

¿Cuántas épocas tarda en converger?
Aproximadamente entre 100 y 300 épocas, dependiendo de la función de activación.

## Ejercicio 2 — Clasificación no lineal

Aprender una frontera circular.

**Parametros iniciales**
Hidden layers: 1
Neuronas : 3
Activacion: Tanh

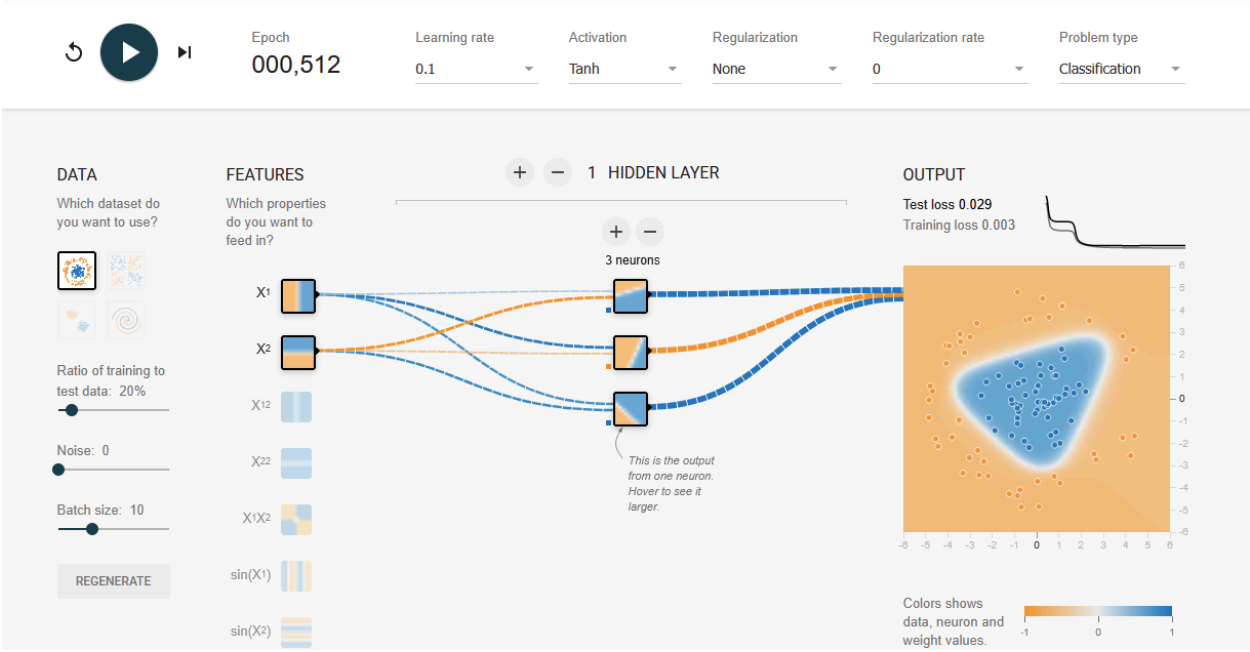


**Parametros Recomendados**
Hidden layers: 2
Neuronas : 3 por capa oculta
Activacion: ReLu
Learning rate: 0.03

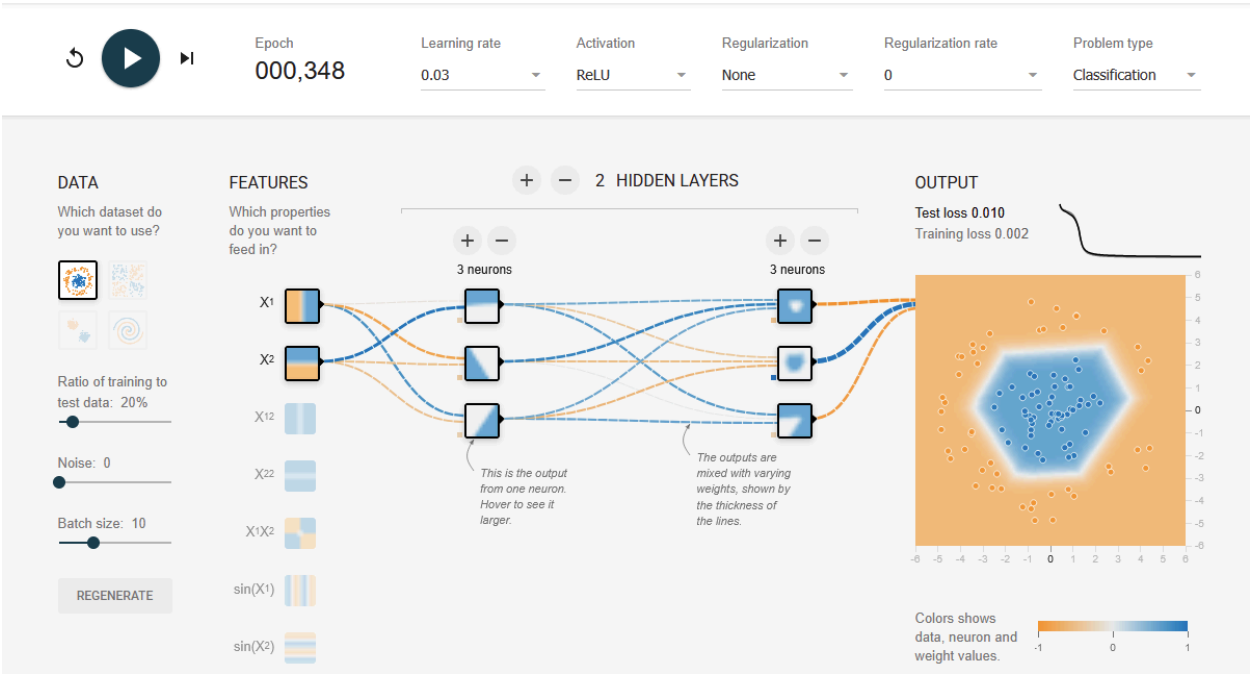


**Justificacion**

Al ser una problema circular una red neuronal simple no aprende la frontera de los datos de una manera apropiada por lo que al agregas más capas y neuronas la red puede aprender este patrón mucho mejor acomodando a los datos

Respuestas

¿Qué ocurre con pocas neuronas?
La red no puede identificar bien la forma circular y la frontera.

¿Cómo cambia la frontera de decisión?
Con más neuronas la frontera se vuelve más curva y se ajusta mejor al círculo.

¿Qué ocurre si agregas una segunda capa?
La red puede aprender una forma más compleja y mejora la clasificación.

## Ejercicio 3 — Overfitting en clasificación

Analizar si aumentar mucho la complejidad del modelo mejora el resultado.

Dataset: Gaussian

**Patron Inicial**

Hidden layer: 1
Neuronas: 2

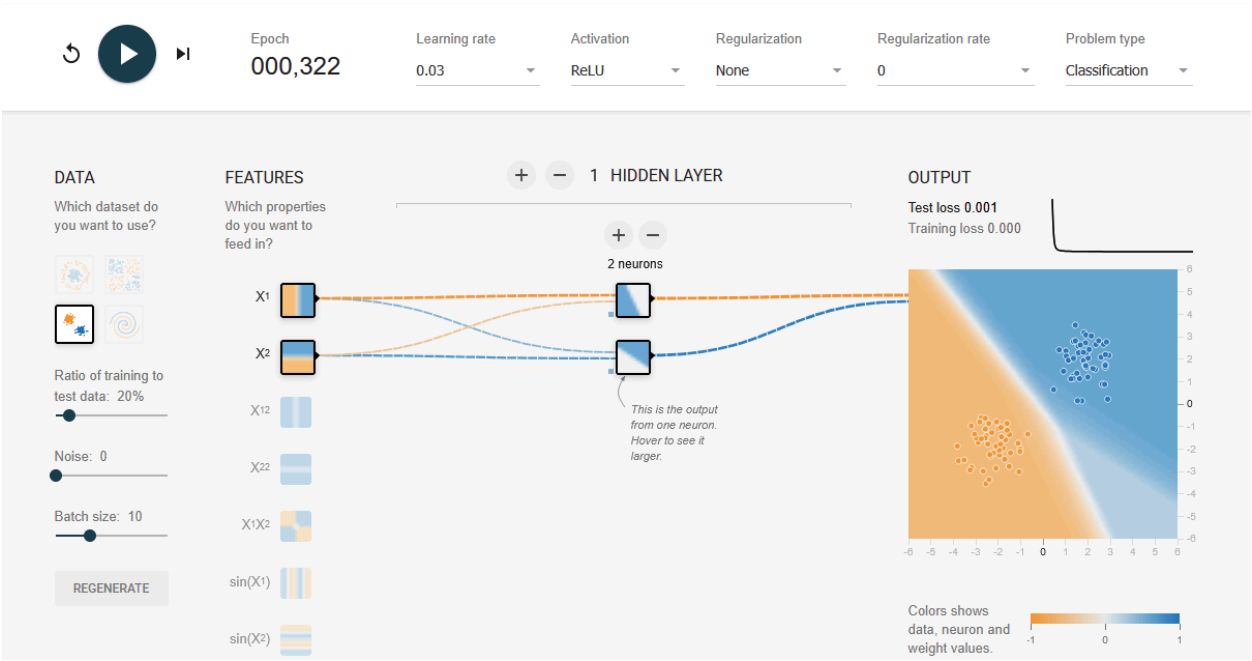


Actividad

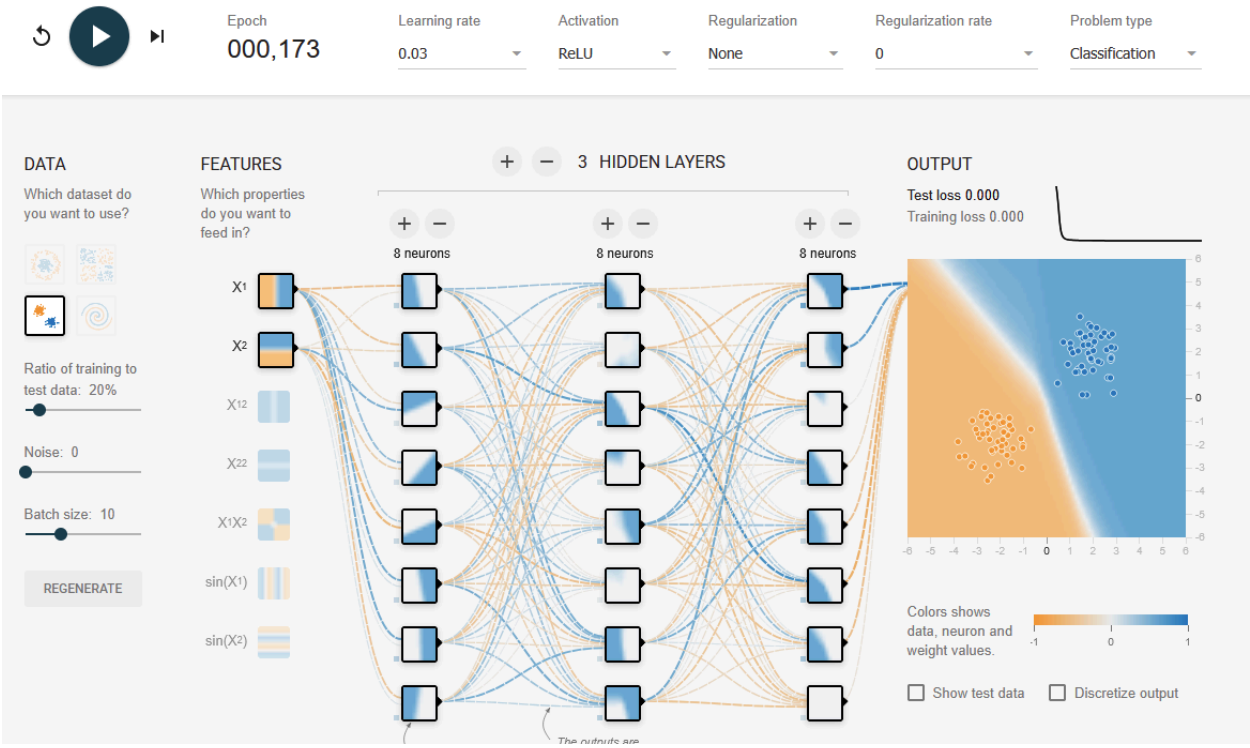


Al hacer esto podemos ver como se sobreentrena la red neuronal aprendiendo patrones demasiado específicos que podamos observar con la línea tan definida, lo cual no permitirá que la red identifique puntos si no tienen ese patrón en especial

**Patron Recomendado**

Hidden layers : 1
Neuronas: 2
Activacion: tahn
Learning rate: 0.03

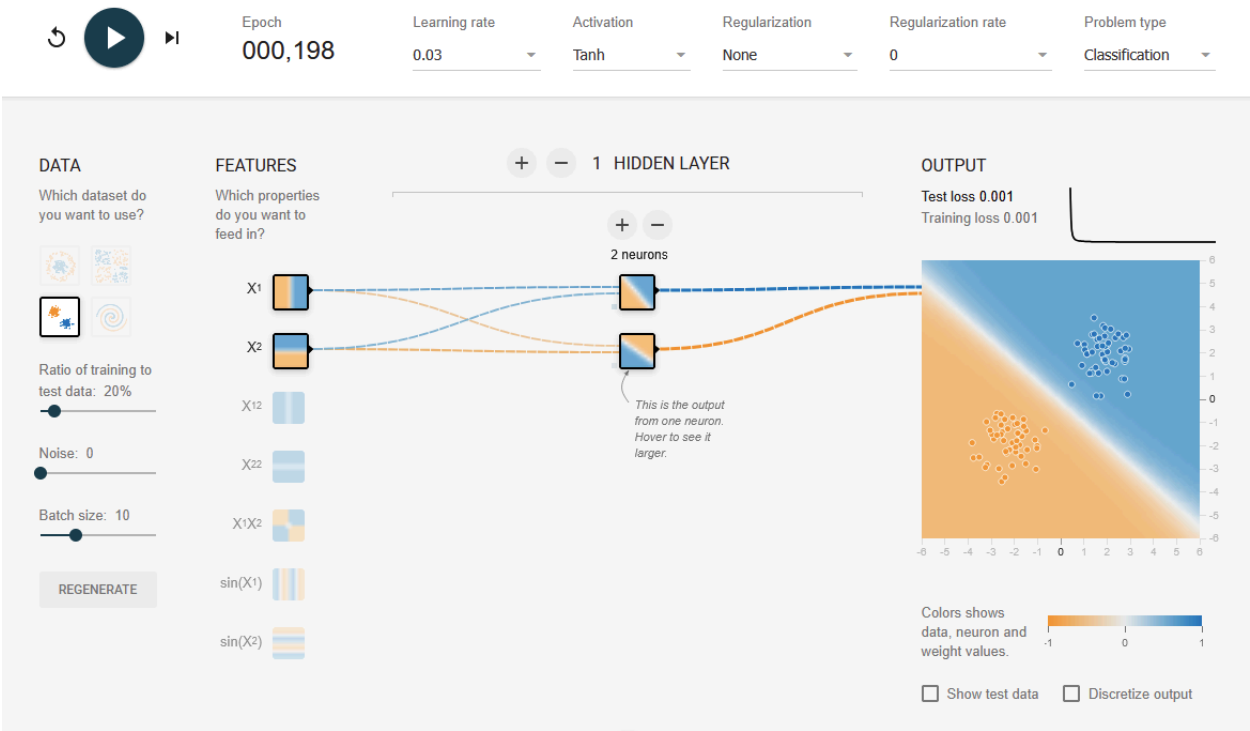


**Justificacion**

En este ejercicio se opto por una red mas simple sin tantas capas ocultas o neuronas con el fin de evitar el sobreentrenamiento para permitir que esta red sea utilizable en un caso real

**Respuestas**

¿La red mejora realmente?
No necesariamente. A veces el modelo más complejo no mejora el resultado.

¿Se vuelve más irregular la frontera?
Sí, la frontera empieza a tener muchas curvas y formas extrañas.

¿Qué indica eso sobre el sobreajuste?
Indica que la red está aprendiendo demasiado los datos de entrenamiento y no generaliza bien.

## Ejercicio 4 — Importancia de las variables

Resolver un problema tipo XOR.

Parametros iniciales

Features Activas

x1
x2

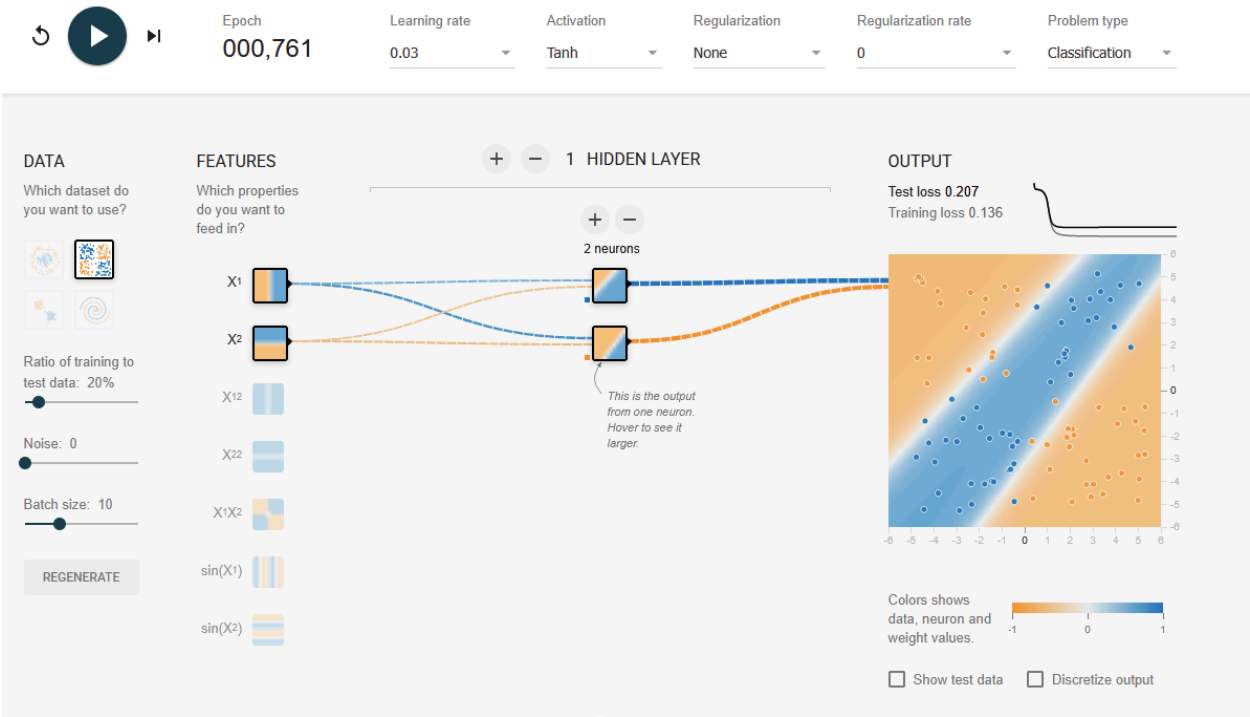


**Recomendado**

Features activas:

x1
x2
$x1^2$
$x2^2$
x1x2

Hidden layers: 1
Neuronas: 4
Activation: Tanh

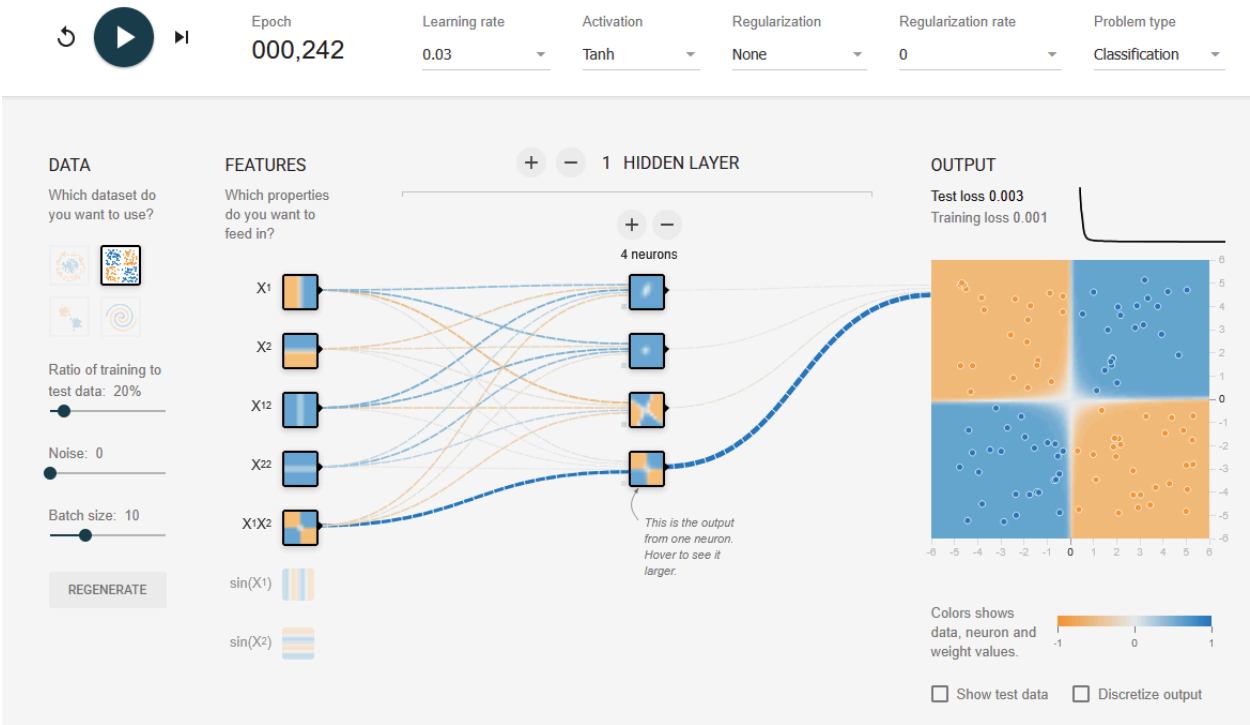


### Justificacion

XOR no puede solucionarse de manera lineal con solo 2 variables, al agregar más variables la red puede aprender los patrones según la separación de los datos

### Respuestas

¿Mejora la clasificación?
Sí, al activar más features la red logra separar mejor los datos.

¿Qué feature ayuda más a resolver el problema?
La interacción x1x2, porque es la relación entre ambas variables.

## Ejercicio 5 — Impacto del tamaño del dataset

**Dataset**: Spiral
**Parametros Iniciales**
• Hidden layers: 2
• Neuronas: 6
• Learning rate: 0.03

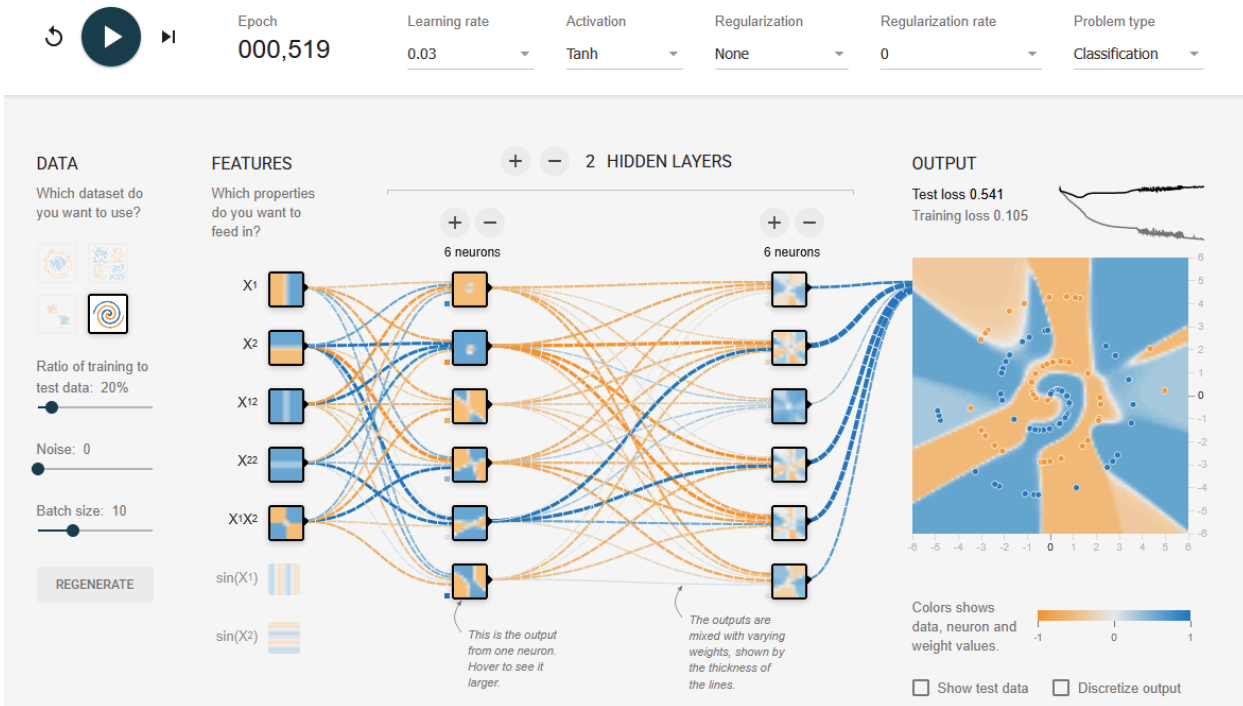


Parámetros recomendados

Hidden layers: 3
Neuronas: 6
Learning rate: 0.03
Train to test ratio 70

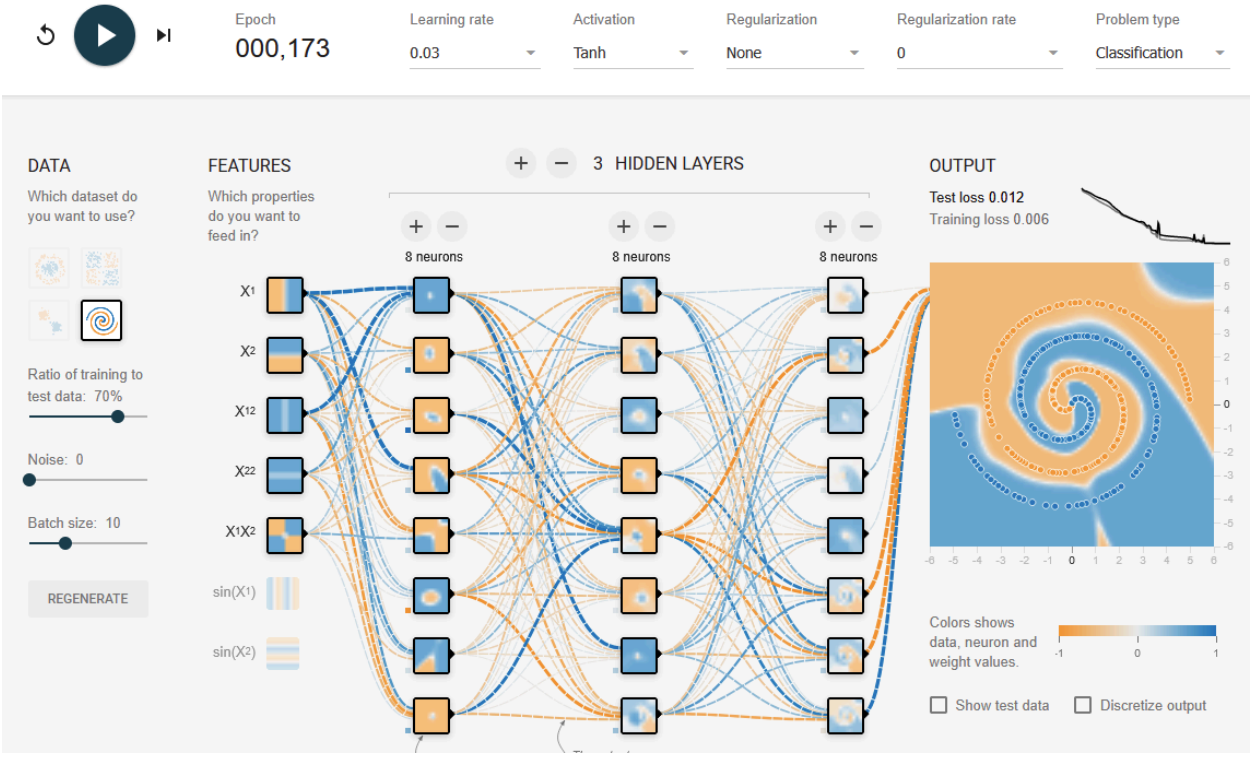


**Justificacion**

Ya que los datos son espiral las fronteras son complicadas para una red neuronal por lo que tener más neuronas y una myor cantidad de datos permitirá a la red entender mejor las fronteras

**Respuestas**
¿La frontera mejora?
Sí, con más datos la frontera se ajusta mejor a la espiral.

¿La red tarda más en entrenar?
No, porque al tener más neuronas y capas aprende más rápido

## Ejercicio 6 — Aproximar función simple

Aproximar una relación lineal entre variables.

**Configuración inicial**

Hidden layer: 0
Learning rate: 0.03

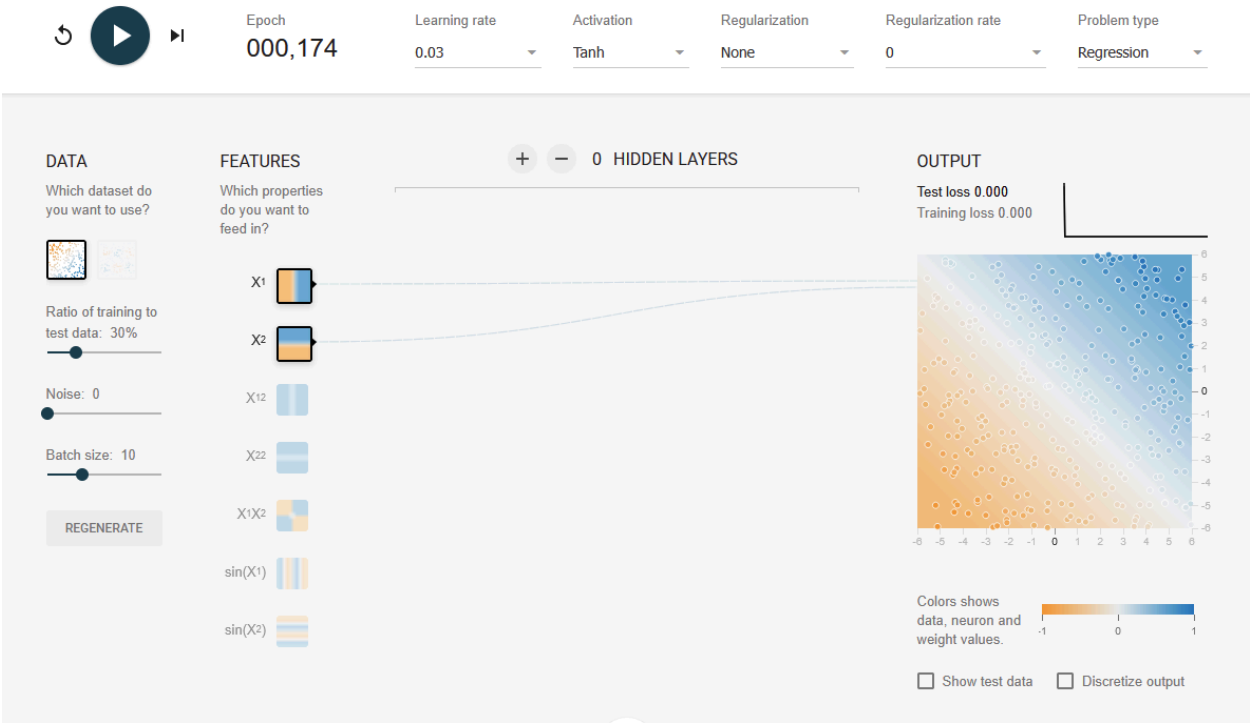


Actividad

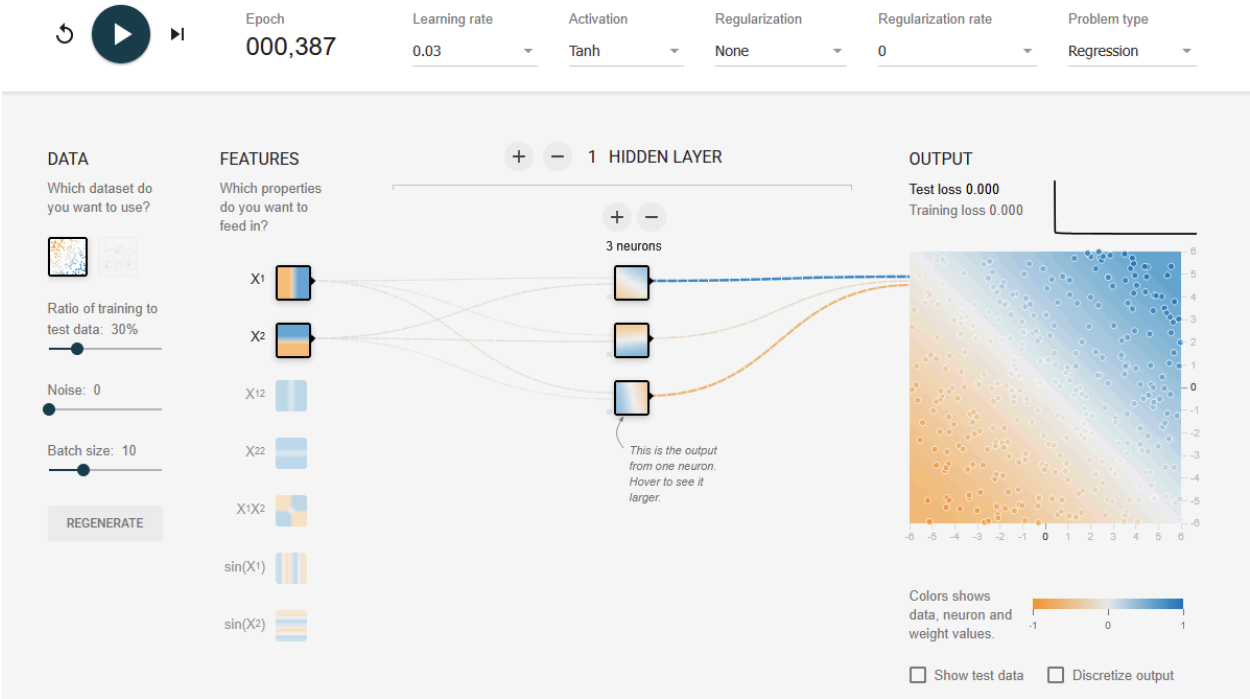


Recomendada

Hidden layer: 0

Learning rate: 0.03

Justificacion

Al ser un problema lineal no necesita una red compleja por lo que actua como regresion lineal

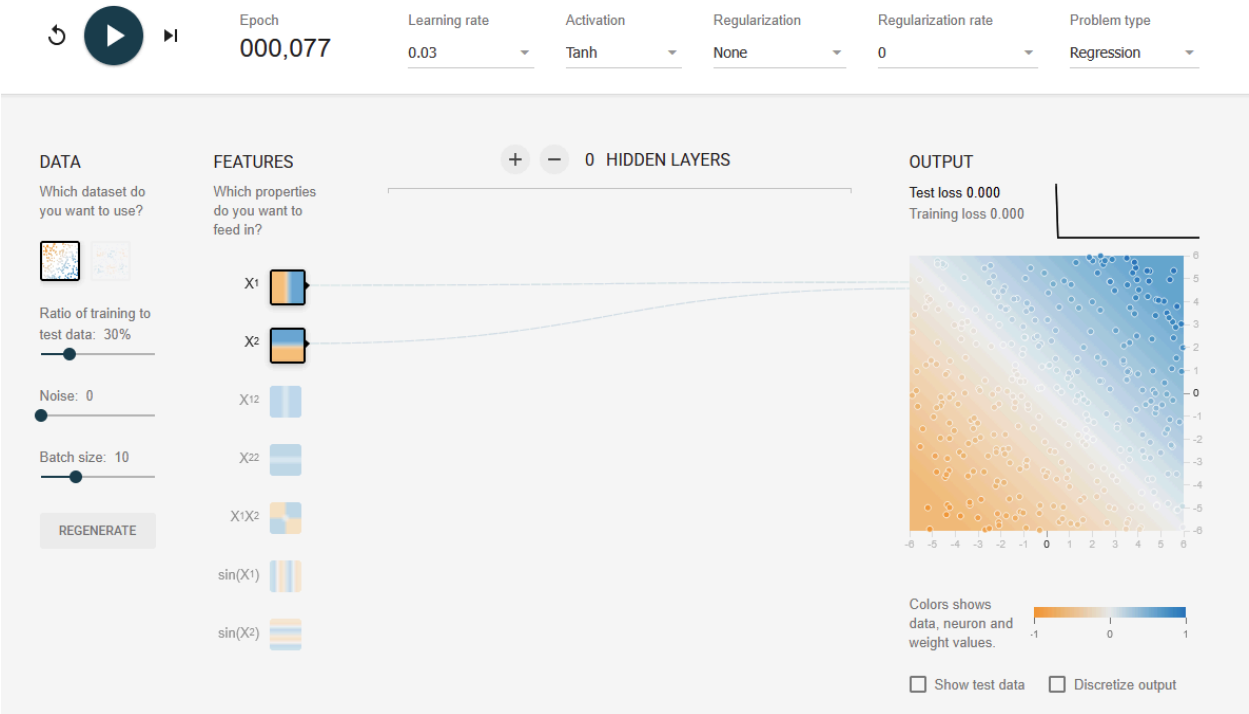


Respuestas

¿Qué cambia en la forma de la función?
La función sigue siendo una línea recta.

¿Se vuelve más flexible?
No, porque el modelo sigue siendo lineal.

## Ejercicio 7 — Aproximar función no lineal

Parámetros iniciales

Features:

x1
$x1^2$

Hidden layers: 1

Neuronas: 4

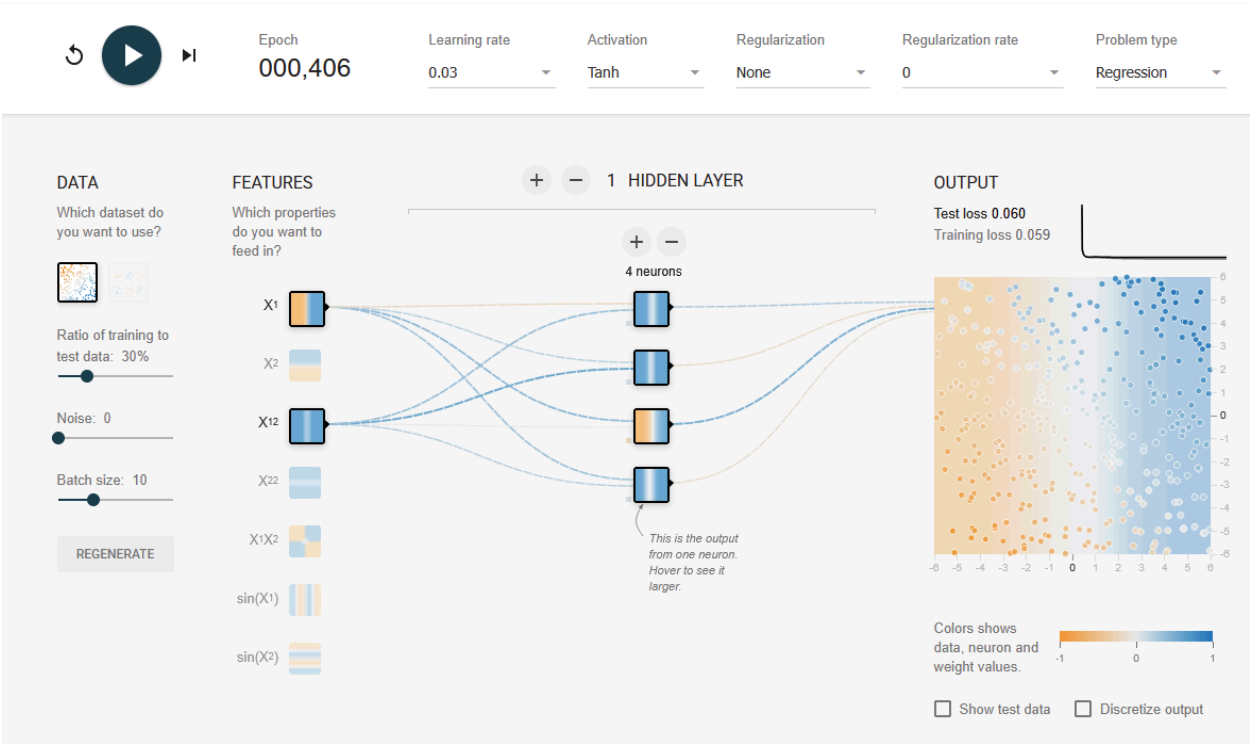


Actividad

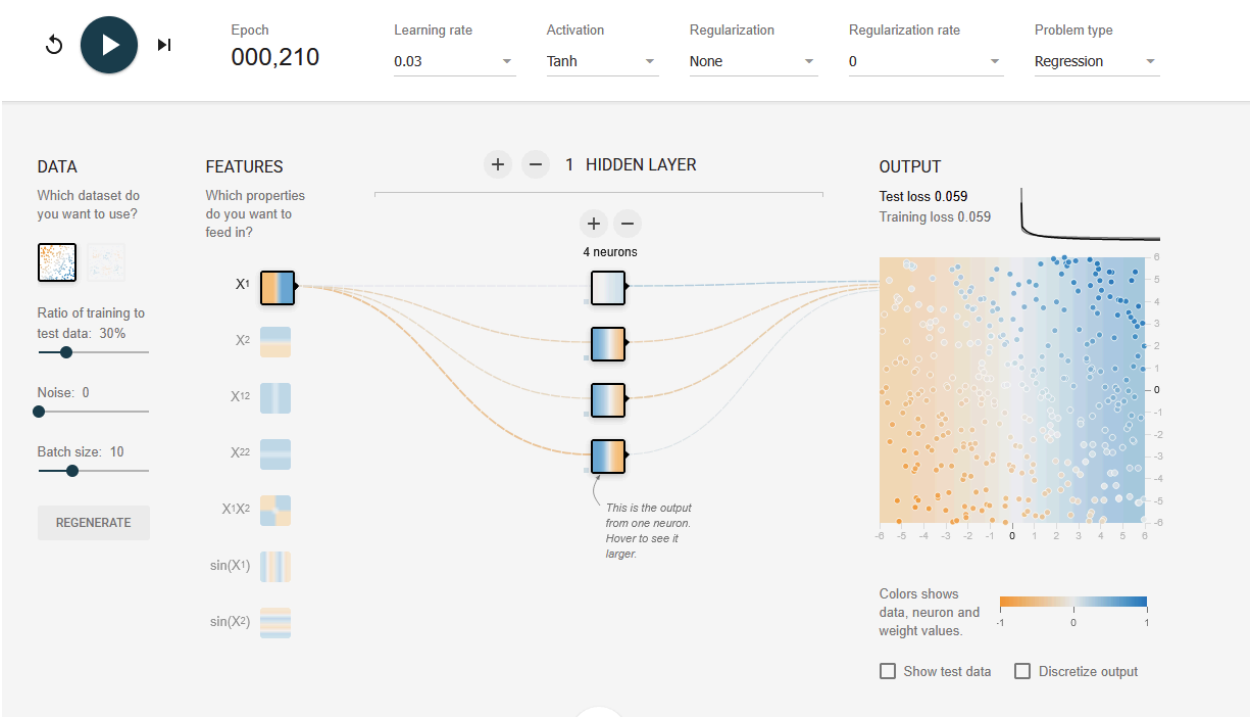

**Parámetros recomendados**

Hidden layers: 1

Neuronas: 4

Features: x1 ,x1² y x2

Activation: Tanh

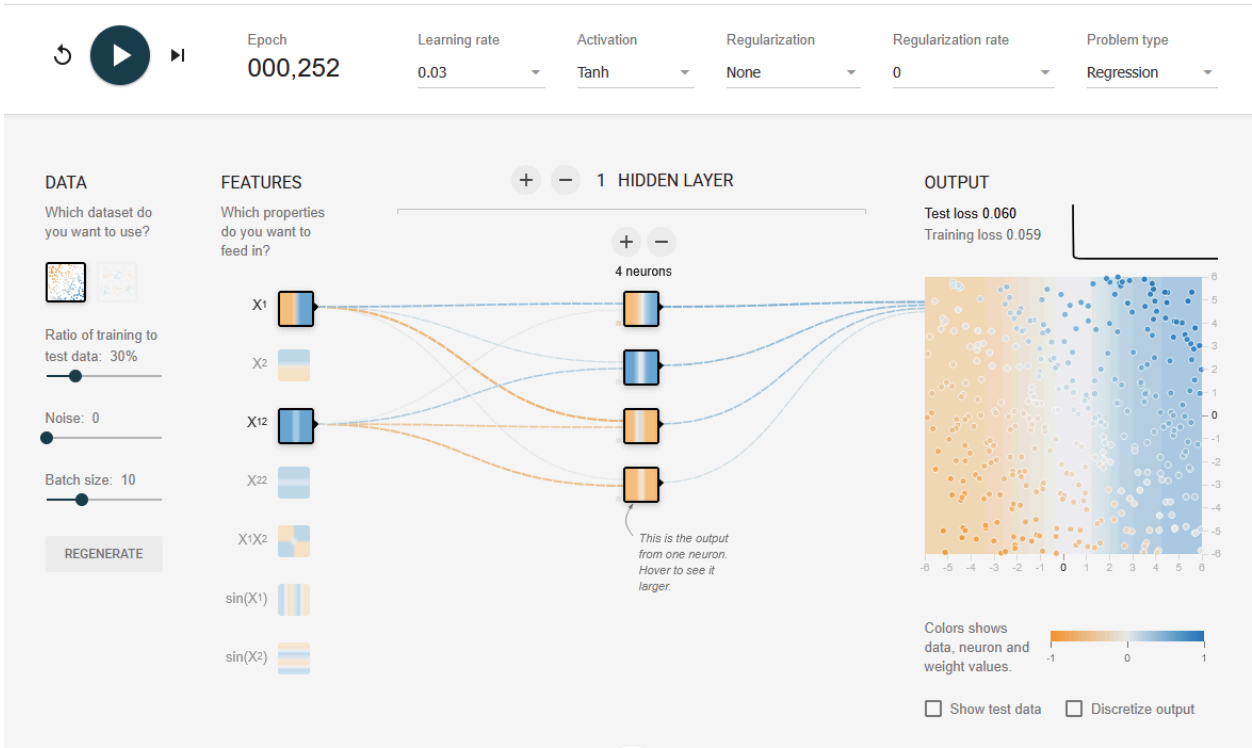


Justificacion

Al seleccionar x2 podemos ver como las relaciones no lineales entre los datos disminuye el error en la predicción y suavizar la curva de los datos ajustándose más al dataset

Respuesta
¿La red pierde capacidad de ajuste?
Sí, cuando se quita x1² la red no puede representar bien la curva.

¿Por qué?
Porque falta la información que se acomoda a los datos

## Ejercicio 8 — Efecto del learning rate

Comprar el learning rate

Configuración Inicial

Hidden layer: 2
Neuronas: 5
Learning rate 0.03

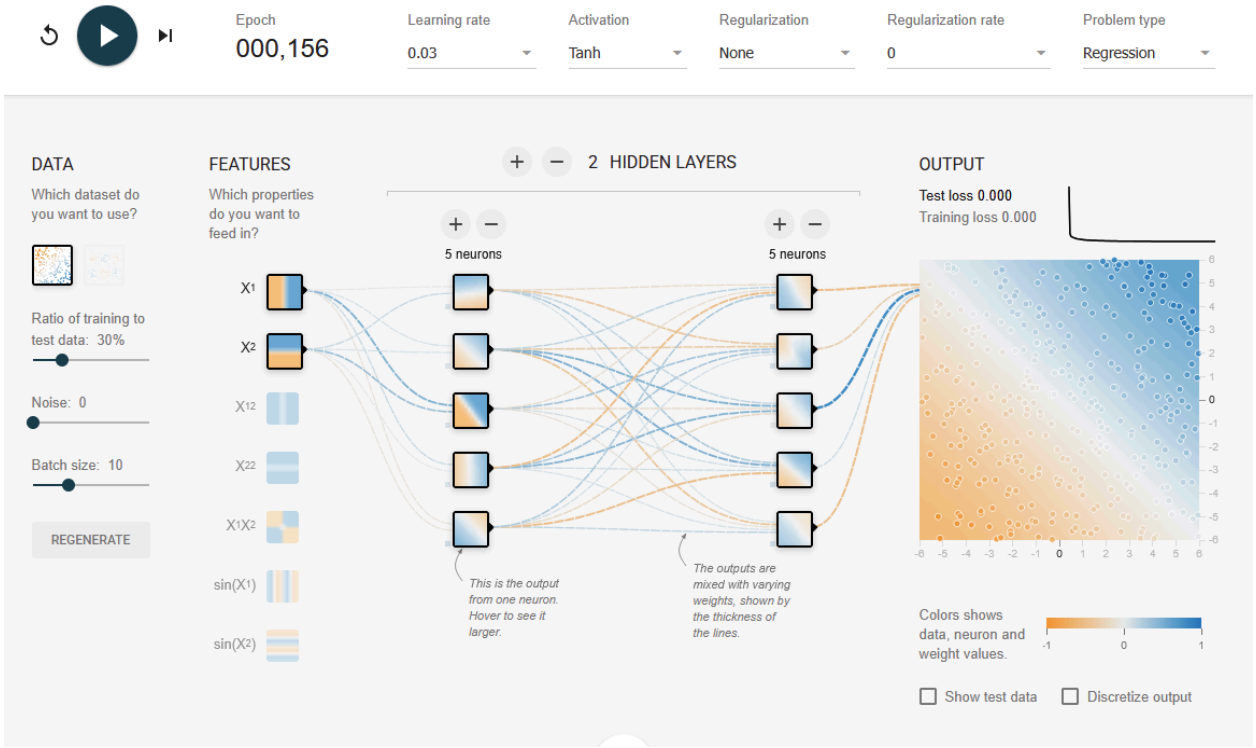


Learning rate 0.00001

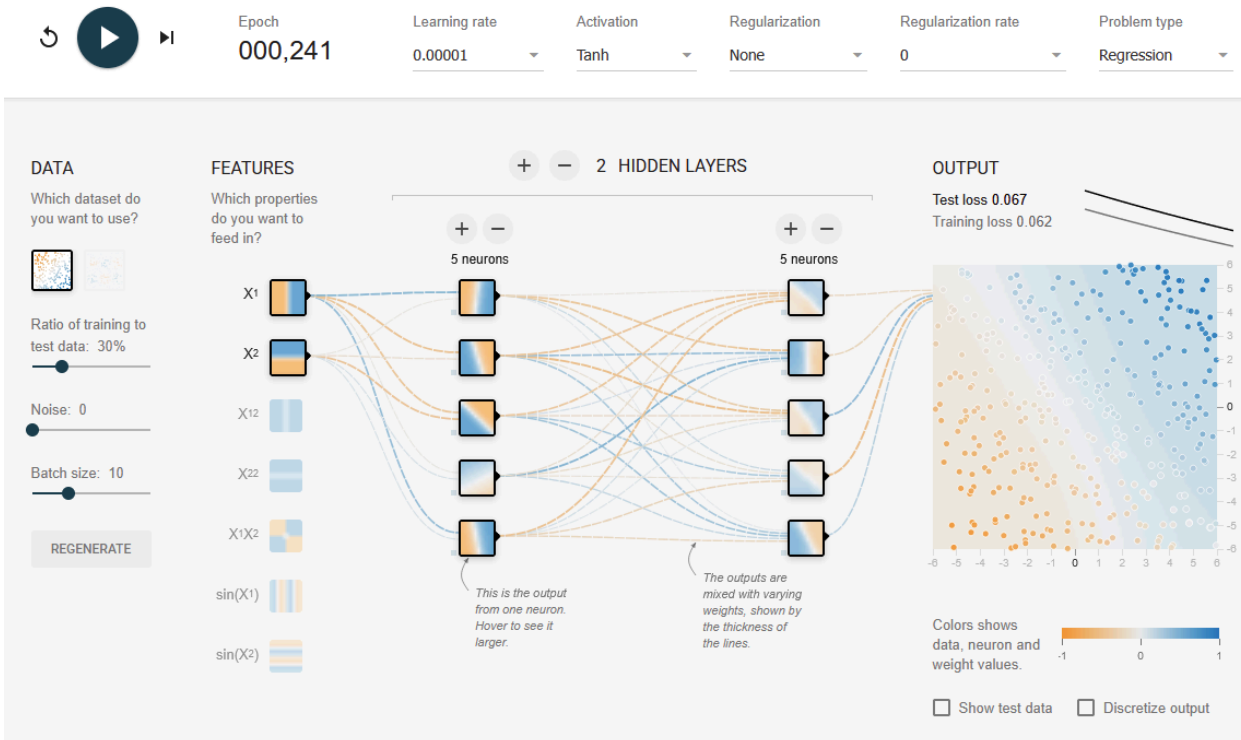


Learning rate 0.03

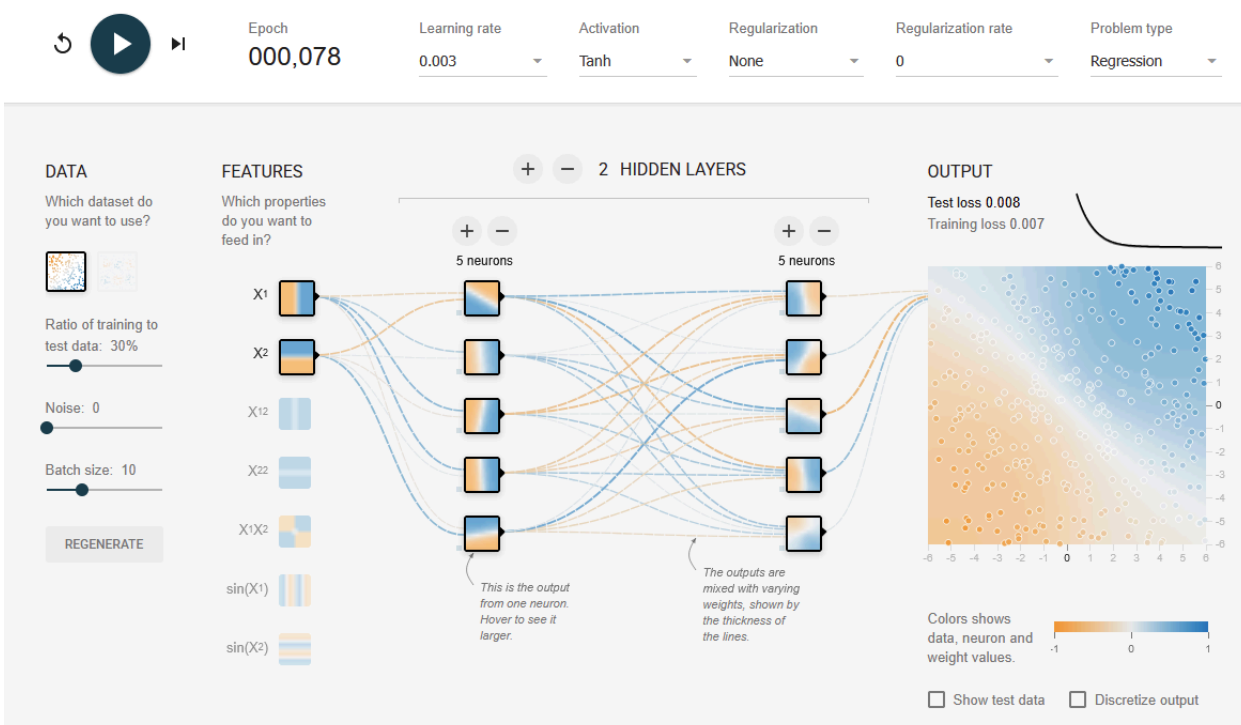


Learning rate 1

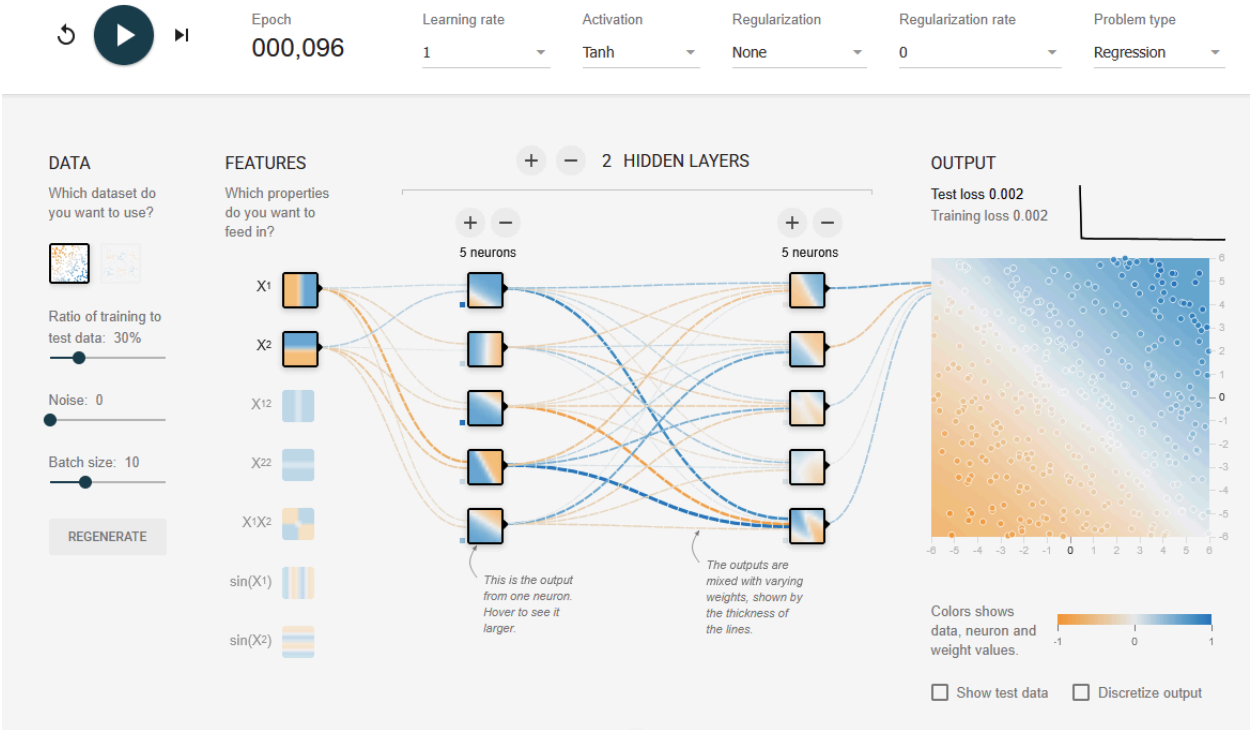


## Parametros recomendados

Hidden layer: 2
Neuronas: 5
Learning rate 0.03

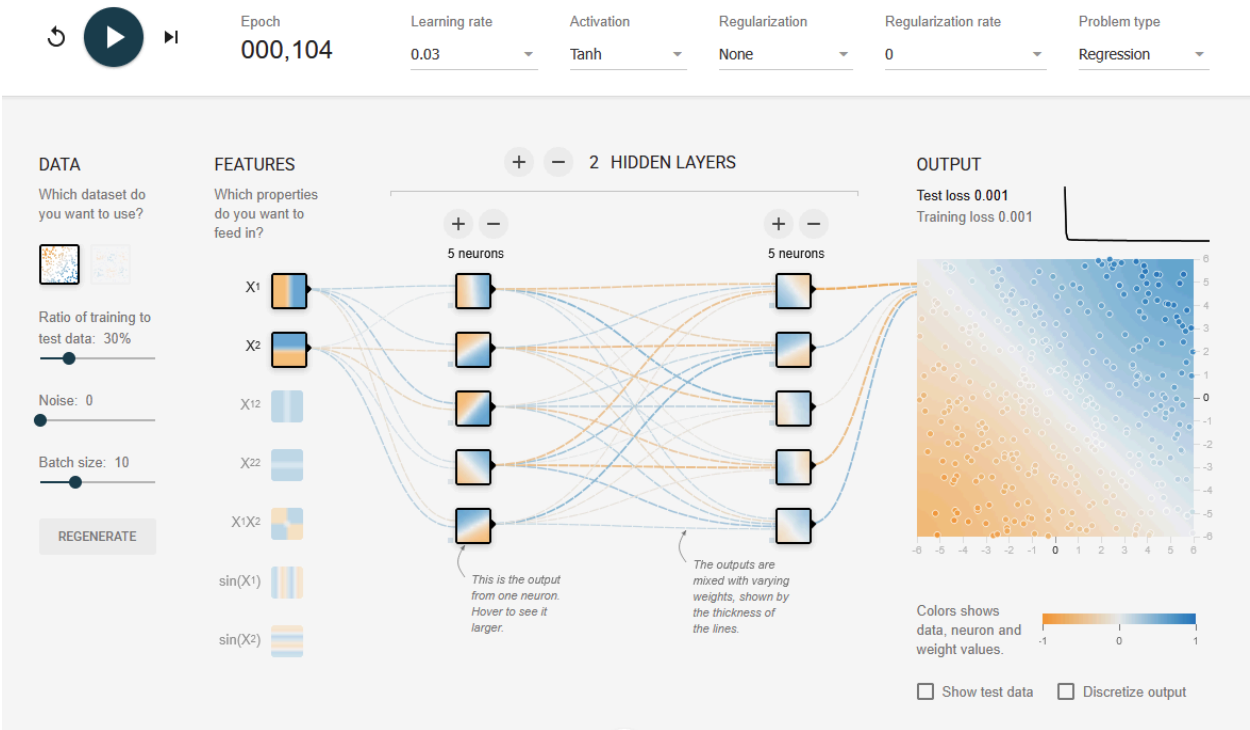


**Justificacion**

Utilizando un Learning rate moderado. Se utilizó 0.03 esto permite que la red neuronal aprenda rápido y apegándose mas a los datos

**Respuestas**

¿Cuál converge más rápido?
El learning rate 0.03.

¿Cuál diverge?
El learning rate 1, porque es demasiado alto y no tiene suficiente detalle

## Ejercicio 9 — Profundidad de red

**Parámetros iniciales**
Hidden layers: 1
Neuronas: 2

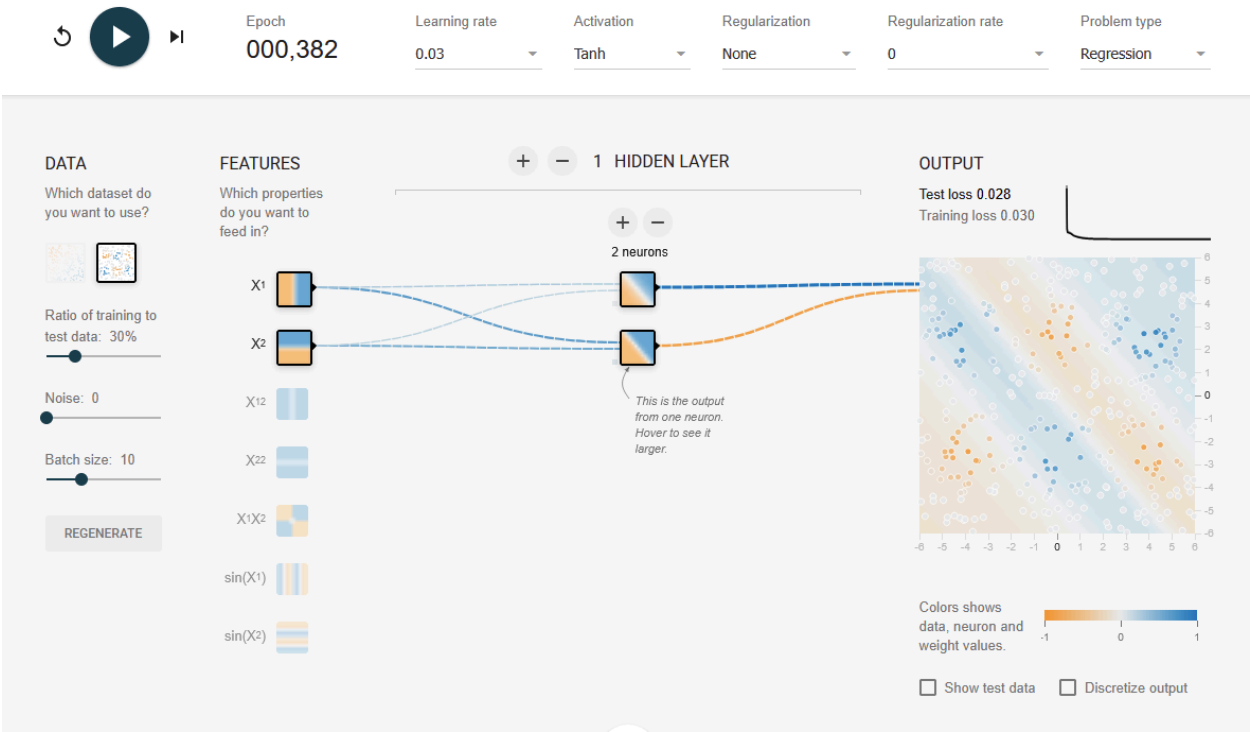


**Parámetros recomendados**
Hidden layers: 3
Neuronas: 8
Activation: ReLu
Learning rate: 0.03

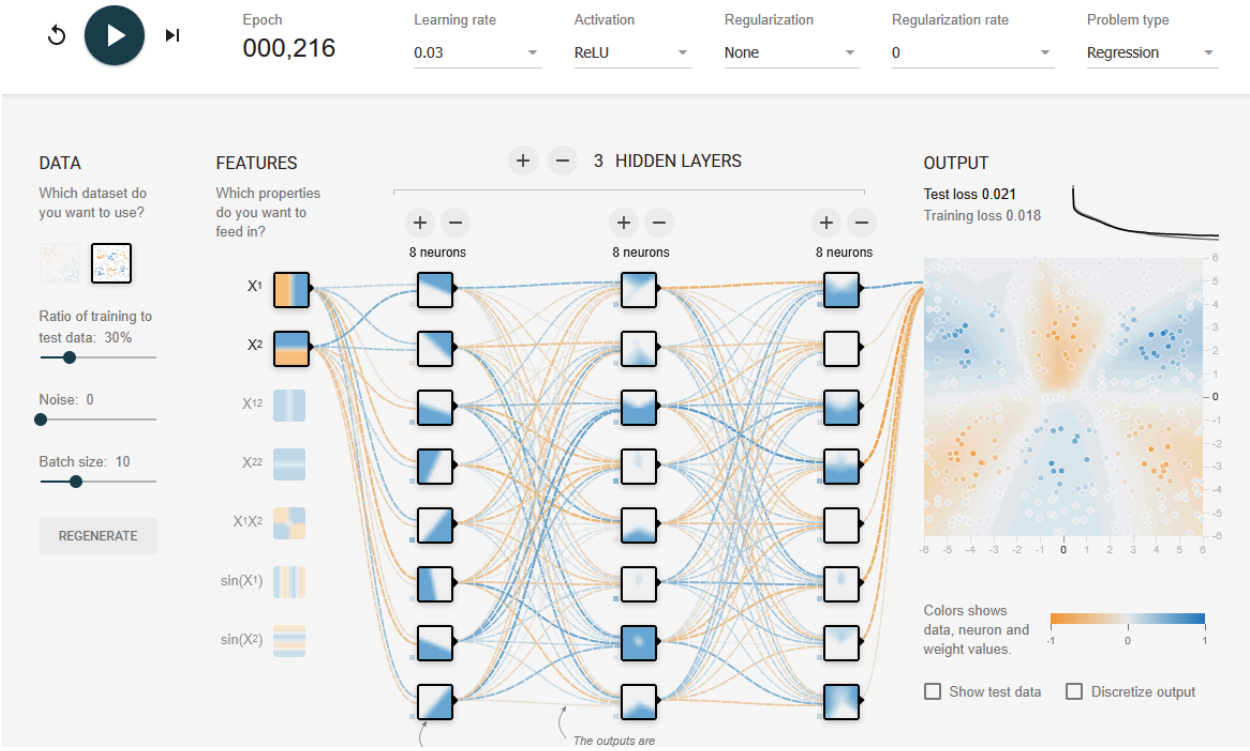


**Justificacion**

Una red con más capas ocultas y neuronas aprendera patrones más complejos lo que permite un mejor rendimiento además de una mejor curva de aprendizaje al utilizar ReLu

**Respuestas**

¿La función predicha se vuelve más compleja?
Sí, la función empieza a tener más curvas y formas.

¿Qué implica mayor profundidad?
Que el modelo tiene más capacidad para aprender patrones complejos.

## Ejercicio 10 — Selección de features

Parámetros iniciales
Features:
x1
X2

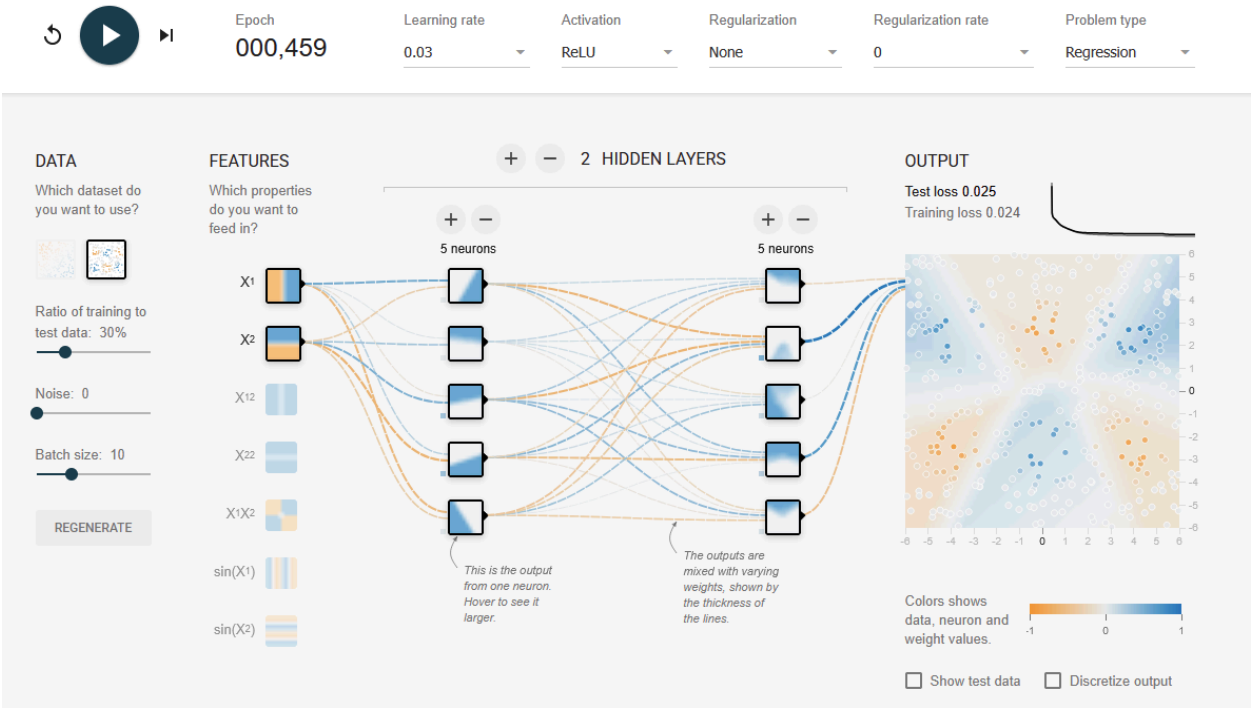


Parámetros recomendados

Features:
x1
x2
$x1^2$
$x2^2$
x1x2

Hidden layers: 2
Neuronas: 5
Activation: ReLu

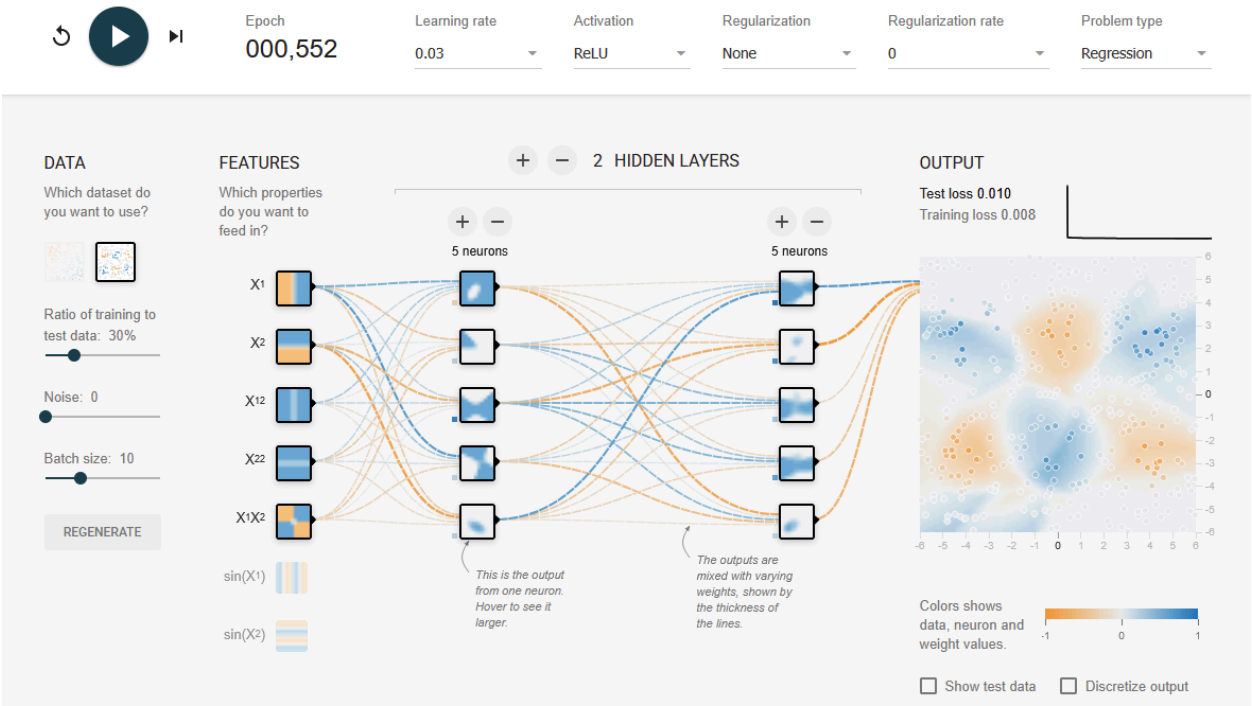


**Justificación**

Agregar nuevas variables permite que el modelo capture relaciones más complejas entre los datos y reduzca el error.

Respuestas

¿Disminuye el error?
Sí, el error disminuye al agregar más features útiles.

¿Qué significa añadir nuevas características?
Significa darle más información al modelo para que pueda aprender mejor los patrones en los datos.